

2η σειρά αναδυόμενων ασκήσεων
Μηχανική μάθηση

Άσκηση 2.1 (Decision Trees - Random Forests)

X_1	X_2	X_3	X_4	Y
1	1	0	0	1
1	1	0	1	1
0	0	1	0	1
0	1	1	1	1
1	0	0	0	1
1	0	1	1	-1
0	1	0	1	-1
1	1	1	1	-1
0	0	0	1	-1

Στην ευρέδση του αλγορίθμου cart, έχω κάνει τους υπολογισμούς για το gini index πρόσβασης του D και όχι του D' , ~~από~~ σε κάθε βήμα απαιτείται συνάρτηση υπολογισμού με βάση το σωστό σύνολο. Νόμος τετραγώνου για διαχωρισμό σε πιθανότητες να το πάρω.

$$a) \text{gini}(\text{Root}) = 1 - \left(\frac{5}{9}\right)^2 - \left(\frac{4}{9}\right)^2 = 0,494$$

$$\text{gini}(X_1=1) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0,48$$

$$\text{gini}(X_1=0) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0,5$$

$$\text{gini}(X_2=1) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0,48$$

$$\text{gini}(X_2=0) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0,5$$

$$\text{gini}(X_3=1) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0,5$$

$$\text{gini}(X_3=0) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0,48$$

$$\text{gini}(X_4=1) = 1 - \left(\frac{2}{6}\right)^2 - \left(\frac{4}{6}\right)^2 = 0,44$$

$$\text{gini}(X_4=0) = 1 - \left(\frac{3}{3}\right)^2 - \left(\frac{0}{3}\right)^2 = 0$$

$$gini(x_1) = \frac{5}{9} \cdot 0,48 + \frac{4}{9} \cdot 0,5 = 0,489$$

$$gini(x_2) = \frac{5}{9} \cdot 0,48 + \frac{4}{9} \cdot 0,5 = 0,489$$

$$gini(x_3) = \frac{4}{9} \cdot 0,5 + \frac{5}{9} \cdot 0,48 = 0,491$$

$$gini(x_4) = \frac{6}{9} \cdot 0,44 + \frac{3}{9} \cdot 0 = 0,293$$


$$g(x_1) = 0,494 - 0,489 = 0,005$$

$$g(x_2) = 0,494 - 0,489 = 0,005$$

$$g(x_3) = 0,494 - 0,491 = 0,003$$


$$g(x_4) = 0,494 - 0,293 = 0,201$$

Με βάση τα παραπάνω, το δέντρο απόφασης που προκύπτει με τη χρήση του κριτηρίου Gini (αλγόριθμος Cart) είναι το ακόλουθο:



β) Παρατηρώ πως τα X_1, X_3 σχετίζονται με το Y σύμφωνα με τη σχέση XOR. Συγκεκριμένα, όταν $X_1 \text{ XOR } X_3 = 1$, τότε $Y = 1$ και όταν $X_1 \text{ XOR } X_3 = -1$, τότε $Y = -1$. Επομένως, ένα πιο εύκολο δέντρο με ακρίβεια 1 είναι το ακόλουθο:

$$(X_1 \text{ XOR } X_3) = \cancel{(X_1 \text{ OR } X_3) \text{ AND } (X_1 \vee \neg X_3) \wedge (\neg X_1 \vee X_3)}$$



γ) 1ο δέντρο

X_1	X_2	X_3	X_4	Y
1	1	0	0	1
0	1	1	1	1
0	1	0	1	-1

$$\text{gini}(\text{Root}) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 0,44$$

$$\text{gini}(X_1=1) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0$$

$$\text{gini}(X_1=0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$\text{gini}(X_2=1) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 0,44$$

$$\text{gini}(X_2=0) = 1 - 0 - 0 = 1$$

$$\text{gini}(X_3=1) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0$$

$$\text{gini}(X_3=0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$\text{gini}(X_4=1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$\text{gini}(X_4=0) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0$$

$$gini(x_1) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 0,5 = 0,33$$

$$gini(x_2) = 1 \cdot 0,44 + 0 \cdot 1 = 0,44$$

$$gini(x_3) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 0,5 = 0,33$$

$$gini(x_4) = \frac{2}{3} \cdot 0,5 + \frac{1}{3} \cdot 0 = 0,33$$


$$ig(x_1) = 0,44 - 0,33 = 0,11$$

$$ig(x_2) = 0,44 - 0,44 = 0$$

$$ig(x_3) = 0,44 - 0,33 = 0,11$$

$$ig(x_4) = 0,44 - 0,33 = 0,11$$

Με βάση τα παραπάνω, το δέντρο απόφασης που προκύπτει με τη χρήση του κριτηρίου Gini είναι το ακόλουθο:



2ο δέντρο:

x_1	x_2	x_3	x_4	Y
1	1	0	1	1
1	0	0	0	1
1	1	1	1	-1

$$gini(Root) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 0,44$$

$$gini(X_1=1) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 0,44$$

$$gini(X_1=0) = 1 - 0 - 0 = 1$$

$$gini(X_2=1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$gini(X_2=0) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0$$

$$gini(X_3=1) = 1 - \left(\frac{0}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0$$

$$gini(X_3=0) = 1 - \left(\frac{2}{2}\right)^2 - \left(\frac{0}{2}\right)^2 = 0$$

$$gini(X_4=1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$gini(X_4=0) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0$$

$$gini(X_L) = 1 \cdot 0,44 + 0 \cdot 1 = 0,44$$

$$gini(X_2) = \frac{2}{3} \cdot 0,5 + \frac{1}{3} \cdot 0 = 0,33$$

$$gini(X_3) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 0 = 0$$

$$gini(X_4) = \frac{2}{3} \cdot 0,5 + \frac{1}{3} \cdot 0 = 0,33$$



$$ig(X_1) = 0,44 - 0,44 = 0$$

$$ig(X_2) = 0,44 - 0,33 = 0,11$$

$$ig(X_3) = 0,44 - 0 = 0,44$$

$$ig(X_4) = 0,44 - 0,33 = 0,11$$

Με βάση τα παραπάνω, το δέντρο απόφασης που προκύπτει με τη χρήση του κριτηρίου Gini είναι το ακόλουθο:



3ο δέντρο:

X_1	X_2	X_3	X_4	Y
0	0	1	0	1
1	0	1	1	-1
0	0	0	1	-1

$$gini(\text{Root}) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = 0,44$$

$$gini(X_1=1) = 1 - \left(\frac{0}{1}\right)^2 - \left(\frac{1}{1}\right)^2 = 0$$

$$gini(X_1=0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$gini(X_2=1) = 1 - 0 - 0 = 1$$

$$gini(X_2=0) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = 0,44$$

$$gini(X_3=1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0,5$$

$$gini(X_3=0) = 1 - \left(\frac{0}{1}\right)^2 - \left(\frac{1}{1}\right)^2 = 0$$

$$gini(X_4=1) = 1 - \left(\frac{1}{1}\right)^2 - \left(\frac{0}{1}\right)^2 = 0$$

$$gini(X_4=0) = 1 - \left(\frac{0}{2}\right)^2 - \left(\frac{2}{2}\right)^2 = 0$$

$$gini(X_1) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 0,5 = 0,33$$

$$gini(X_2) = 0 \cdot 1 + 1 \cdot 0,44 = 0,44$$

$$gini(X_3) = \frac{2}{3} \cdot 0,5 + \frac{1}{3} \cdot 0 = 0,33$$

$$gini(X_4) = \frac{2}{3} \cdot 0 + \frac{1}{3} \cdot 0 = 0$$


$$ig(X_1) = 0,44 - 0,33 = 0,11$$

$$ig(X_2) = 0,44 - 0,44 = 0$$

$$ig(X_3) = 0,44 - 0,33 = 0,11$$

$$ig(X_4) = 0,44 - 0 = 0,44$$

Με βάση τα παραπάνω, το δέντρο απόφασης που προκύπτει με τη χρήση του κριτηρίου Gini είναι το ακόλουθο:






Το Random Forest είναι το ακόλουθο:

1ο δέντρο

2ο δέντρο

3ο δέντρο



Άσκηση 9.2 (Εφαρμογή του K-Means σε συνθετικά και πραγματικά δεδομένα)

$$X = \{(2,3), (3,2), (1,2), (4,5), (5,4), (3,4), (6,4), (6,5)\}$$

α) $m=2$ κλάσεις, αρχικά κέντρα κλάσεων $(3,3)$ και $(4,4)$

K-means algorithm

$$\Theta_1(0) = (3,3), \Theta_2(0) = (4,4)$$

$$\bullet \quad b(1)=1, b(2)=1, b(3)=1, b(4)=2, b(5)=2, b(6)=1, \\ b(7)=2, b(8)=2$$

$$\Theta_1(1) = \left(\frac{2+3+1+3}{4}, \frac{3+2+2+4}{4} \right) = (2,25, 2,75)$$

$$\Theta_2(1) = \left(\frac{4+5+6+6}{4}, \frac{5+4+4+5}{4} \right) = (5,25, 4,5)$$

$$\bullet \quad b(1)=1, b(2)=1, b(3)=1, b(4)=2, b(5)=2, b(6)=1, \\ b(7)=2, b(8)=2$$

$$\bullet \quad \Theta_1(2) = \left(\frac{2+3+1+3}{4}, \frac{3+2+2+4}{4} \right) = (2,25, 2,75)$$

$$\Theta_2(2) = (5,25, 4,5)$$

Οι θέσεις των τελικών κέντρων είναι $(2,25, 2,75)$ και $(5,25, 4,5)$

Στην 1η κλάση καταλαμβάνουν τα $(2,3), (3,2), (1,2), (3,4)$ και στη 2η κλάση τα $(4,5), (5,4), (6,4), (6,5)$

$$dc(x_1, x_2) = 1 - \cos(x_1, x_2) = 1 - \frac{x_1 \cdot x_2}{\|x_1\| \|x_2\|} = 1 - \frac{(1 \cdot 3 + 5 \cdot 4)}{\sqrt{1^2 + 5^2} \sqrt{3^2 + 4^2}} = 1 - \frac{23}{\sqrt{26} \cdot 5} = 0,098 = dc(x_2, x_1)$$

$$dc(x_1, x_3) = 1 - \frac{(1 \cdot 0 + 5 \cdot 2)}{\sqrt{26} \cdot \sqrt{4 + 25}} = 1 - \frac{10}{\sqrt{26} \sqrt{29}} = 1 - \frac{(1 \cdot 0 + 5 \cdot 2)}{\sqrt{26} \sqrt{4}} = 1 - \frac{10}{2\sqrt{26}} = 0,019 = dc(x_3, x_1)$$

$$dc(x_1, x_4) = 1 - \frac{(1 \cdot 5 + 5 \cdot 5)}{\sqrt{26} \sqrt{4}} = 1 - \frac{25}{\sqrt{26} \sqrt{4}} = 0,234 = dc(x_4, x_1)$$

$$dc(x_1, x_5) = 1 - \frac{(1 \cdot 2 + 5 \cdot 6)}{\sqrt{26} \sqrt{40}} = 1 - \frac{32}{\sqrt{26} \sqrt{40}} = 0,008 = dc(x_5, x_1)$$

$$dc(x_1, x_6) = 1 - \frac{(1 \cdot 3 + 5 \cdot 3)}{\sqrt{26} \sqrt{18}} = 1 - \frac{18}{\sqrt{26} \sqrt{18}} = 0,168 = dc(x_6, x_1)$$

$$dc(x_1, x_7) = 1 - \frac{(1 \cdot 2 + 5 \cdot 3)}{\sqrt{26} \sqrt{13}} = 1 - \frac{17}{\sqrt{26} \sqrt{13}} = 0,075 = dc(x_7, x_1)$$

$$dc(x_1, x_8) = 1 - \frac{(1 \cdot 4 + 5 \cdot 2)}{\sqrt{26} \sqrt{20}} = 1 - \frac{14}{\sqrt{26} \sqrt{20}} = 0,386 = dc(x_8, x_1)$$

$$dc(x_2, x_3) = 1 - \frac{(3 \cdot 0 + 4 \cdot 2)}{5 \sqrt{4}} = 1 - \frac{8}{10} = 0,2 = dc(x_3, x_2)$$

$$dc(x_2, x_4) = 1 - \frac{(3 \cdot 5 + 4 \cdot 4)}{5 \sqrt{41}} = 1 - \frac{31}{5\sqrt{41}} = 0,032 = dc(x_4, x_2)$$

$$dc(x_2, x_5) = 1 - \frac{(3 \cdot 2 + 4 \cdot 6)}{5 \sqrt{40}} = 1 - \frac{30}{5\sqrt{40}} = 0,051 = dc(x_5, x_2)$$

$$dc(x_2, x_6) = 1 - \frac{(3 \cdot 3 + 4 \cdot 3)}{5 \sqrt{18}} = 1 - \frac{21}{5\sqrt{18}} = 0,01 = dc(x_6, x_2)$$

$$dc(x_2, x_4) = 1 - \frac{(3 \cdot 2 + 4 \cdot 3)}{5\sqrt{13}} = 1 - \frac{18}{5\sqrt{13}} = 0,002 = dc(x_4, x_2)$$

$$dc(x_2, x_8) = 1 - \frac{(3 \cdot 4 + 4 \cdot 2)}{5\sqrt{20}} = 1 - \frac{20}{5\sqrt{20}} = 0,106 = dc(x_8, x_2)$$

$$dc(x_3, x_4) = 1 - \frac{(0 \cdot 5 + 2 \cdot 4)}{2\sqrt{4}} = 1 - \frac{8}{2\sqrt{4}} = 0,375 = dc(x_4, x_3)$$

$$dc(x_3, x_5) = 1 - \frac{(0 \cdot 2 + 2 \cdot 6)}{2\sqrt{40}} = 1 - \frac{12}{2\sqrt{40}} = 0,051 = dc(x_5, x_3)$$

$$dc(x_3, x_6) = 1 - \frac{(0 \cdot 3 + 2 \cdot 3)}{2\sqrt{18}} = 1 - \frac{6}{2\sqrt{18}} = 0,293 = dc(x_6, x_3)$$

$$dc(x_3, x_7) = 1 - \frac{(0 \cdot 2 + 2 \cdot 3)}{2\sqrt{13}} = 1 - \frac{6}{2\sqrt{13}} = 0,168 = dc(x_7, x_3)$$

$$dc(x_3, x_8) = 1 - \frac{(0 \cdot 4 + 2 \cdot 2)}{2\sqrt{20}} = 1 - \frac{4}{2\sqrt{20}} = 0,553 = dc(x_8, x_3)$$

$$dc(x_4, x_5) = 1 - \frac{(5 \cdot 2 + 4 \cdot 6)}{\sqrt{41} \cdot \sqrt{40}} = 1 - \frac{34}{\sqrt{41} \cdot \sqrt{40}} = 0,160 = dc(x_5, x_4)$$

$$dc(x_4, x_6) = 1 - \frac{(5 \cdot 3 + 4 \cdot 3)}{\sqrt{41} \cdot \sqrt{18}} = 1 - \frac{27}{\sqrt{41} \cdot \sqrt{18}} = 0,006 = dc(x_6, x_4)$$

$$dc(x_4, x_7) = 1 - \frac{(5 \cdot 2 + 4 \cdot 3)}{\sqrt{41} \cdot \sqrt{13}} = 1 - \frac{22}{\sqrt{41} \cdot \sqrt{13}} = 0,047 = dc(x_7, x_4)$$

$$dc(x_4, x_8) = 1 - \frac{(5 \cdot 4 + 4 \cdot 2)}{\sqrt{41} \cdot \sqrt{20}} = 1 - \frac{28}{\sqrt{41} \cdot \sqrt{20}} = 0,022 = dc(x_8, x_4)$$

$$dc(x_5, x_6) = 1 - \frac{(9 \cdot 3 + 6 \cdot 3)}{\sqrt{40} \cdot \sqrt{18}} = 1 - \frac{24}{\sqrt{40} \cdot \sqrt{18}} = 0,106 = dc(x_6, x_5)$$

$$d_c(x_5, x_7) = 1 - \frac{(2 \cdot 2 + 6 \cdot 3)}{\sqrt{40} \cdot \sqrt{13}} = 1 - \frac{22}{\sqrt{40} \sqrt{13}} = 0,035 = d_c(x_7, x_5)$$

$$d_c(x_5, x_8) = 1 - \frac{(2 \cdot 4 + 6 \cdot 2)}{\sqrt{40} \cdot \sqrt{20}} = 1 - \frac{20}{\sqrt{40} \sqrt{20}} = 0,293 = d_c(x_8, x_5)$$

$$d_c(x_6, x_7) = 1 - \frac{(3 \cdot 2 + 3 \cdot 3)}{\sqrt{18} \cdot \sqrt{13}} = 1 - \frac{15}{\sqrt{18} \sqrt{13}} = 0,019 = d_c(x_7, x_6)$$

$$d_c(x_6, x_8) = 1 - \frac{(3 \cdot 4 + 3 \cdot 2)}{\sqrt{18} \cdot \sqrt{20}} = 1 - \frac{18}{\sqrt{18} \sqrt{20}} = 0,051 = d_c(x_8, x_6)$$

$$d_c(x_7, x_8) = 1 - \frac{(2 \cdot 4 + 3 \cdot 2)}{\sqrt{13} \cdot \sqrt{20}} = 1 - \frac{14}{\sqrt{13} \sqrt{20}} = 0,132 = d_c(x_8, x_7)$$

$$P(x) = \begin{bmatrix} 0 & 0,098 & 0,019 & 0,234 & 0,008 & 0,168 & 0,075 & 0,386 \\ 0,098 & 0 & 0,2 & 0,032 & 0,051 & 0,01 & 0,002 & 0,106 \\ 0,019 & 0,2 & 0 & 0,375 & 0,051 & 0,293 & 0,168 & 0,553 \\ 0,234 & 0,032 & 0,375 & 0 & 0,168 & 0,006 & 0,047 & 0,092 \\ 0,008 & 0,051 & 0,051 & 0,16 & 0 & 0,106 & 0,055 & 0,293 \\ 0,168 & 0,01 & 0,293 & 0,006 & 0,106 & 0 & 0,019 & 0,051 \\ 0,075 & 0,002 & 0,168 & 0,047 & 0,035 & 0,019 & 0 & 0,132 \\ 0,386 & 0,106 & 0,553 & 0,092 & 0,293 & 0,051 & 0,132 & 0 \end{bmatrix}$$

γ) Ο αριθμητικός τετραγωνικός σταθμισμένος απόστασης δίνει με βάση των πιθανά γεγονότα $P(x)$ έχει ως εξής:

$$d(C_i, C_j) = 0,002 \Rightarrow i=2, j=7 \Rightarrow \text{συγκριση } \{x_2, x_7\} = C_9$$

$$d(C_9, C_s) = \min \{d(C_2, C_s), d(C_7, C_s)\}$$

$$d(C_1, C_9) = \min \{d(C_1, C_2), d(C_1, C_7)\} = 0,075$$

$$d(C_3, C_9) = 0,168, d(C_4, C_9) = 0,032, d(C_5, C_9) = 0,035$$

$$d(C_6, C_9) = 0,001, d(C_8, C_9) = 0,106$$

	$\{x_1, x_2, x_3\}$						
$P_1(x) =$	0	0,075	0,019	0,234	0,008	0,168	0,386
	0,075	0	0,168	0,032	0,035	0,01	0,106
	0,019	0,168	0	0,375	0,051	0,293	0,553
	0,234	0,032	0,375	0	0,16	0,006	0,022
	0,008	0,035	0,051	0,16	0	0,106	0,293
	0,168	0,01	0,293	0,006	0,106	0	0,051
	0,386	0,106	0,553	0,022	0,293	0,051	0

• $d(C_i, C_j) = 0,006 \Rightarrow i = 6, j = 4 \Rightarrow \text{συγκρίνουμε } \{x_4, x_6\} = C_q'$

$d(C_1, C_q') = 0,168, d(C_q, C_q') = 0,01, d(C_3, C_q') = 0,293,$

$d(C_5, C_q') = 0,106, d(C_8, C_q') = 0,022$

	$\{x_1, x_2\}$	$\{x_4, x_6\}$	
$P_2(x) =$	0	0,075	0,019
	0,075	0	0,168
	0,019	0,168	0
	0,168	0,001	0,293
	0,008	0,035	0,051
	0,386	0,106	0,553

• $d(C_i, C_j) = 0,008 \Rightarrow i = 1, j = 5 \Rightarrow \text{συγκρίνουμε } \{x_1, x_5\} = C_q''$

$d(C_q', C_q'') = 0,035, d(C_3, C_q'') = 0,019, d(C_q', C_q'') = 0,106,$

$d(C_8, C_q'') = 0,293$

	$\sum x_1, x_3$	$\sum x_2, x_3$	$\sum x_4, x_6$		
$P_3(x) =$	0	0,035	0,019	0,106	0,293
	0,035	0	0,168	0,01	0,106
	0,019	0,168	0	0,293	0,553
	0,106	0,01	0,293	0	0,022
	0,293	0,106	0,553	0,022	0

• $d(C_i, C_j) = 0,01 \Rightarrow i = 4,6, j = 2,7 \Rightarrow$ συγχώνευση $\{x_2, x_7\} = C_q^{III}$

$$d(C_q^{II}, C_q^{III}) = 0,035, d(C_3, C_q^{III}) = 0,168, d(C_8, C_q^{III}) =$$

$$= 0,022$$

$$P_4(x) = \begin{bmatrix} & C_q^{II} & C_q^{III} & C_3 & C_8 \\ C_q^{II} & 0 & 0,035 & 0,019 & 0,293 \\ C_q^{III} & 0,035 & 0 & 0,168 & 0,022 \\ C_3 & 0,019 & 0,168 & 0 & 0,553 \\ C_8 & 0,293 & 0,022 & 0,553 & 0 \end{bmatrix}$$

• $d(C_i, C_j) = 0,019 \Rightarrow i = 1,5, j = 3 \Rightarrow$ συγχώνευση $\{x_1, x_5\} = C_q^{IV}$

$$d(C_q^{III}, C_q^{IV}) = 0,035, d(C_8, C_q^{IV}) = 0,293$$

~~$$P_5(x) = \begin{bmatrix} & C_q^{III} & C_q^{IV} & C_8 \\ C_q^{III} & 0 & 0,035 & 0,022 \\ C_q^{IV} & 0,035 & 0 & 0,293 \\ C_8 & 0,022 & 0,293 & 0 \end{bmatrix}$$~~

$$P_5(x) = \begin{bmatrix} & C_q^{IV} & C_q^{III} & C_8 \\ C_q^{IV} & 0 & 0,035 & 0,293 \\ C_q^{III} & 0,035 & 0 & 0,022 \\ C_8 & 0,293 & 0,022 & 0 \end{bmatrix}$$

• $d(C_i, C_j) = 0,022 \Rightarrow i = 8, j = 2,4,6,7 \Rightarrow$ συγχώνευση


$$\{x_2, x_4, x_6, x_7, x_8\} = C_q^{V}$$

$$d(C_q^{IV}, C_q^{V}) = 0,035$$

$$P_6(x) = \begin{bmatrix} & C_q^{V} \\ C_q^{IV} & 0 & 0,035 \\ C_q^{V} & 0,035 & 0 \end{bmatrix}$$

• συγχώνευση $\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$

Το δένδροδιάγραμμα εγγύτητας της ελαφιοτήτος του ιεραρχικού αλγόριθμου αυτού δόσας είναι το ακόλουθο:



δ) Ο αριθμός ιεραρχικής ομαδοποίησης πηχούς δέσφαι με βάση των πίνακα οφφέντας PCx) έχει ως εξής:

$$\bullet d(C_i, C_j) = 0,002 \Rightarrow i = 2, j = 7 \Rightarrow \text{συχώνευση } \{x_2, x_7\} = C_q$$

$$d(C_1, C_q) = 0,098, d(C_3, C_q) = 0,2, d(C_4, C_q) = 0,047$$

$$d(C_5, C_q) = 0,051, d(C_6, C_q) = 0,019, d(C_8, C_q) = 0,132$$

$$P_1(x) = \begin{bmatrix} 0 & 0,098 & 0,019 & 0,234 & 0,008 & 0,168 & 0,386 \\ 0,098 & 0 & 0,2 & 0,047 & 0,051 & 0,019 & 0,132 \\ 0,019 & 0,2 & 0 & 0,385 & 0,051 & 0,293 & 0,553 \\ 0,234 & 0,047 & 0,385 & 0 & 0,16 & 0,006 & 0,022 \\ 0,008 & 0,051 & 0,051 & 0,16 & 0 & 0,106 & 0,293 \\ 0,168 & 0,019 & 0,293 & 0,006 & 0,106 & 0 & 0,051 \\ 0,386 & 0,132 & 0,553 & 0,022 & 0,293 & 0,051 & 0 \end{bmatrix}$$

$$\bullet d(C_i, C_j) = 0,006 \Rightarrow \text{συχώνευση } \{x_4, x_6\} = C_{q'}$$

$$d(C_1, C_{q'}) = 0,234, d(C_q, C_{q'}) = 0,047, d(C_3, C_{q'}) = 0,385$$

$$d(C_5, C_{q'}) = 0,16, d(C_8, C_{q'}) = 0,051$$

$$P_2(x) = \begin{matrix} & \{x_1, x_7\} & & \{x_4, x_6\} \\ \begin{matrix} \{x_1, x_7\} \\ \{x_4, x_6\} \end{matrix} & \begin{bmatrix} 0 & 0,098 & 0,019 & 0,234 & 0,008 & 0,386 \\ 0,098 & 0 & 0,2 & 0,047 & 0,051 & 0,132 \\ 0,019 & 0,2 & 0 & 0,375 & 0,051 & 0,553 \\ 0,234 & 0,047 & 0,375 & 0 & 0,16 & 0,051 \\ 0,008 & 0,051 & 0,051 & 0,16 & 0 & 0,293 \\ 0,386 & 0,132 & 0,553 & 0,051 & 0,293 & 0 \end{bmatrix} \end{matrix}$$

• $d(C_i, C_j) = 0,008 \Rightarrow \sigma_{ij}$ χώνευση $\{x_1, x_5\} = C_q''$

$d(C_q, C_q'') = 0,098$, $d(C_3, C_q'') = 0,051$, $d(C_q', C_q'') = 0,234$,

$d(C_8, C_q'') = 0,386$

$$P_3(x) = \begin{matrix} & \{x_1, x_5\} & & \{x_4, x_6\} \\ \begin{matrix} \{x_1, x_5\} \\ \{x_4, x_6\} \end{matrix} & \begin{bmatrix} 0 & 0,098 & 0,051 & 0,234 & 0,386 \\ 0,098 & 0 & 0,2 & 0,047 & 0,132 \\ 0,051 & 0,2 & 0 & 0,375 & 0,553 \\ 0,234 & 0,047 & 0,375 & 0 & 0,051 \\ 0,386 & 0,132 & 0,553 & 0,051 & 0 \end{bmatrix} \end{matrix}$$

• $d(C_i, C_j) = 0,047 \Rightarrow \sigma_{ij}$ χώνευση $\{x_2, x_4, x_6, x_7\} = C_q'''$

$d(C_q'', C_q''') = 0,234$, $d(C_3, C_q''') = 0,375$, $d(C_8, C_q''') =$

$= 0,132$

~~$$P_4(x) = \begin{matrix} & C_q'' & C_q''' & C_3 & C_8 \\ \begin{matrix} C_q'' \\ C_q''' \\ C_3 \\ C_8 \end{matrix} & \begin{bmatrix} 0 & 0,234 & 0,375 & 0,132 \\ 0,234 & 0 & 0,375 & 0 \\ 0,375 & 0,375 & 0 & 0 \\ 0,132 & 0 & 0 & 0 \end{bmatrix} \end{matrix}$$~~

$$P_4(x) = \begin{matrix} & C_q'' & C_q''' & C_3 & C_8 \\ \begin{matrix} C_q'' \\ C_q''' \\ C_3 \\ C_8 \end{matrix} & \begin{bmatrix} 0 & 0,234 & 0,051 & 0,386 \\ 0,234 & 0 & 0,375 & 0,132 \\ 0,051 & 0,375 & 0 & 0,553 \\ 0,386 & 0,132 & 0,553 & 0 \end{bmatrix} \end{matrix}$$

• $d(C_i, C_j) = 0,051 \Rightarrow \sigma_{ij}$ χώνευση $\{x_1, x_3, x_5\} = C_q''''$

$d(C_q''', C_q''') = 0,375$, $d(C_8, C_q''') = 0,553$

$$P_5(x) = \begin{matrix} & C_q'''' & C_q'''' & C_8 \\ \begin{matrix} C_q'''' \\ C_q'''' \\ C_8 \end{matrix} & \begin{bmatrix} 0 & 0,375 & 0,553 \\ 0,375 & 0 & 0,132 \\ 0,553 & 0,132 & 0 \end{bmatrix} \end{matrix}$$


• $d(C_i, C_j) = 0,132 \Rightarrow$ συγχώνευση $\{x_1, x_4, x_6, x_7, x_8\} = C_9^{(1)}$

$$d(C_9^{(1)}, C_9^{(1)}) = 0,553$$

$$P_6(x) = \begin{bmatrix} 0 & 0,553 \\ 0,553 & 0 \end{bmatrix}$$

• συγχώνευση $\{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8\}$

Το δένδροδιαγράμμα εγγύτητας της εφαρμογής του ιεραρχικού αλγόριθμου απλού δείχνει είναι το ακόλουθο



ε) Συγκρίνοντας τα αποτελέσματα των δύο προηγούμενων ερωτημάτων, παρατηρούμε πως οι ομαδοποιήσεις που γίνονται σε κάθε βήμα του αλγόριθμου είναι αριθμικά οι ίδιες, με τη μόνη διαφορά ότι στον ιεραρχικό αλγόριθμο πλήρως δείχνει οι συγχωνεύσεις γίνονται σε μεγαλύτερες τιμές του μέτρου ανομοιογένειας $d_C(x,y)$. Για τον προσδιορισμό της βέλτιστης ομαδοποίησης σε κάθε περίπτωση από τα αντίστοιχα δένδροδιαγράμματα, θα την υπολογίσουμε με βάση το κριτήριο της μέγιστης απόστασης συγχώνευσης, δηλαδή θα επιλέξει η ομαδοποίηση που η τιμή του μέτρου ανομοιογένειας στην οποία αυτή σχηματίστηκε παρουσιάζει μεγαλύτερη απόκλιση από την προηγούμενη ή την επόμενη της. Έτσι, στον αλγόριθμο

απλού δεσφαι, η βέλτιστη ομαδοποίηση είναι η $\{\{x_1, x_3, x_5\}, \{x_2, x_4, x_6, x_7, x_8\}\}$ με απόδοση:

$$(0,051 - 0,022) + (0,022 - 0,019) = 0,032$$

2^{ων} αλγόριθμο πλήρους δεσφαι, η βέλτιστη ομαδοποίηση είναι η:

$\{\{x_1, x_3, x_5\}, \{x_2, x_4, x_6, x_7, x_8\}\}$ με απόδοση

$$(0,553 - 0,132) + (0,132 - 0,051) = 0,502$$

Άσκηση 2.4 (Θεωρία PCA)

$x_n \in \mathbb{R}^1$, $n=1, \dots, N$ ακολουθία τυχαίων διανυσμάτων με μηδενικό μέσο και δείγματικό πίνακα συνδιασποράς

$$\hat{\Sigma} = \frac{1}{N} \sum_{n=1}^N x_n x_n^T$$

πραγματικό

Αναζητούμε τον υπόχωρο διάστασης $m \leq 1$ στον οποίο μεγιστοποιείται η διασπορά των προβολών των δεδομένων. Ο υπόχωρος αυτός ορίζεται με βάση m αμοιβαία ορθογώνια μοναδιαία διανύσματα u_i , $i=1, \dots, m$ που αντιστοιχούν σε m άξονες ή κατευθύνσεις.

a) $m=1$

Η προβολή του x_n στον άξονα που ορίζεται από το διάνυσμα u_1 είναι $y_n = u_1^T x_n$

$$\begin{aligned} V[y] &= E[y_n^2] = E[(u_1^T x_n)^2] = u_1^T E[x_n x_n^T] u_1 = u_1^T \hat{\Sigma} u_1 \\ &= u_1^T \hat{\Sigma} u_1 \end{aligned}$$

$E[x_n] = 0$
μηδενικός μέσος

Η διασπορά $V[y]$ μεγιστοποιείται για $\|u_1\| = 1 \Leftrightarrow u_1^T u_1 = 1$

$$L(u, \lambda) = u^T \hat{\Sigma} u - \lambda(u^T u - 1)$$

$$\frac{\partial L(u, \lambda)}{\partial u} = 2\hat{\Sigma}u - 2\lambda u = 0 \Rightarrow \hat{\Sigma}u = \lambda u$$

Άρα το u είναι ιδιοδιάνυσμα του $\hat{\Sigma}$ και λ η αντιστοιχία ιδιοτιμή του. Εφόσον θέλουμε να μεγιστοποιήσουμε τη διασπορά $u^T \hat{\Sigma} u = \lambda$, αρκεί να επιλέξουμε τη μέγιστη ιδιοτιμή λ_1 και το αντιστοιχό ιδιοδιάνυσμα u_1 . Επομένως, το u_1 είναι το ιδιοδιάνυσμα που αντιστοιχεί στη μεγαλύτερη ιδιοτιμή λ_1 του $\hat{\Sigma}$.

$$b) V[p_2] = \sum_{i=1}^2 E[(u_i^T x)^2] = \sum_{i=1}^2 u_i^T \hat{\Sigma} u_i$$

Για τη μεγιστοποίηση της διασποράς στον υπόχωρο αυτό, ψάχνουμε τα u_1, u_2 που μεγιστοποιούν το

$$u_1^T \hat{\Sigma} u_1 + u_2^T \hat{\Sigma} u_2 \text{ υπό τους περιορισμούς } \|u_1\| = 1, \|u_2\| = 1, u_1^T u_2 = 0$$

Για u_1 ; η διασπορά ^{στην 1η άξονα} μεγιστοποιείται όταν το u_1 είναι το ιδιοδιάνυσμα που αντιστοιχεί στη μέγιστη ιδιοτιμή λ_1 του $\hat{\Sigma}$: $\hat{\Sigma}u_1 = \lambda_1 u_1$.

Για u_2 , έχουμε το ακόλουθο πρόβλημα βελτιστοποίησης:

$$\max \{ u_2^T \hat{\Sigma} u_2 : \|u_2\| = 1 \text{ και } u_1^T u_2 = 0 \}$$

$$L(u_2, \lambda, \mu) = u_2^T \hat{\Sigma} u_2 - \lambda(u_2^T u_2 - 1) - \mu u_1^T u_2$$

$$\frac{\partial L(u_2, \lambda, \mu)}{\partial u_2} = 2\hat{\Sigma}u_2 - 2\lambda u_2 - \mu u_1 = 0 \Rightarrow u_1^T \hat{\Sigma} u_2 -$$

$$-2u_1^T u_2 \lambda - \mu u_1^T u_1 = 0 \Rightarrow -\mu = 0 \Rightarrow \mu = 0$$

$$\text{Επομένως } \hat{\Sigma} u_2 = \lambda u_2$$

Οπότε το u_2 είναι ιδιοδιάνυσμα του $\hat{Z}$. Για να ικανοποιούνται οι δύο περιορισμοί επιλέγουμε τη δεύτερη μεγαλύτερη ιδιοτιμή λ_2 και το αντίστοιχο ιδιοδιάνυσμα. Επομένως, τα u_1, u_2 είναι τα ιδιοδιανύσματα που αντιστοιχούν στις δύο μεγαλύτερες ιδιοτιμές λ_1 και λ_2 του $\hat{Z}$.

$$g) \forall [p, m] = \sum_{i=1}^m u_i^T \hat{Z} u_i \quad \text{με περιορισμούς } \|u_i\| = 1 \text{ και } u_i^T u_j = 0 \text{ για } i \neq j, i, j = 1, 2, \dots, m$$

Αυτό σημαίνει ότι τα διανύσματα $u_1, u_2, \dots, u_m$ πρέπει να είναι μοναδιαία και αμοιβαία ορθογώνια.

$$L(u_1, \dots, u_m, \lambda_1, \dots, \lambda_m, \mu_{ij}) = \sum_{i=1}^m u_i^T \hat{Z} u_i - \sum_{i=1}^m \lambda_i (u_i^T u_i - 1) - \sum_{i=1}^m \sum_{\substack{j=1 \\ j \neq i}}^m \mu_{ij} u_i^T u_j$$

Για κάθε $i = 1, \dots, m$ έχουμε

$$\frac{\partial L}{\partial u_i} = 2\hat{Z}u_i - 2\lambda_i u_i - \sum_{j=1, j \neq i}^m \mu_{ij} u_j = 0 \Leftrightarrow$$

$$\Leftrightarrow u_i^T \hat{Z} u_i - \lambda_i u_i^T u_i - \sum_{j=1, j \neq i}^m \mu_{ij} u_i^T u_j = 0 \quad \begin{matrix} u_i^T u_i = 1 \\ u_i^T u_j = 0, i \neq j \end{matrix}$$

$$\Leftrightarrow \hat{Z} u_i = \lambda_i u_i$$

Επομένως, κάθε u_i είναι ιδιοδιάνυσμα του $\hat{Z}$ και η διασπορά $u_i^T \hat{Z} u_i$ είναι ίση με την αντίστοιχη ιδιοτιμή λ_i . Για να μεγιστοποιήσουμε τη συνολική διασπορά, επιλέγουμε τα m μεγαλύτερα $\lambda_1, \dots, \lambda_m$ και τα αντίστοιχα ιδιοδιανύσματα $u_1, \dots, u_m$. Συνεπώς, τα $u_1, \dots, u_m$ είναι τα ιδιοδιανύσματα του πίνακα $\hat{Z}$ που αντιστοιχούν στις m μεγαλύτερες ιδιοτιμές $\lambda_1, \dots, \lambda_m$ του $\hat{Z}$.

δ) Η συνολική διασπορά των δεδομένων ορίζεται ως το άθροισμα των τετραγώνων των αποκλίσεων των διανυσμάτων x_n από το μέγεθος μέσο, δηλαδή

$$\begin{aligned} \text{Συνολική διασπορά} &= \sum_{n=1}^N \|x_n\|^2 = N \cdot \text{Trace}(\hat{\Sigma}) = \\ &= N \cdot \sum_{i=1}^I \lambda_i, \text{ όπου } \lambda_i \text{ οι ιδιοτιμές του } \hat{\Sigma}. \end{aligned}$$

Όπως αποδείξαμε στο γ) ερώτημα, η διασπορά που ερμηνεύεται από τις πρώτες m κύριες συνιστώσες δίνεται από το άθροισμα των πρώτων m μεγαλύτερων ιδιοτιμών του $\hat{\Sigma}$, δηλαδή

$$V[p, m] = \sum_{i=1}^m \lambda_i$$

Το ποσοστό ρ της συνολικής διασποράς που ερμηνεύεται από τις πρώτες m κύριες συνιστώσες είναι το πηλίκο της διασποράς που ερμηνεύεται από αυτές προς τη συνολική διασπορά, δηλαδή

$$\rho = \frac{\sum_{i=1}^m \lambda_i}{\frac{1}{N} \sum_{n=1}^N \|x_n\|^2} = \frac{N \sum_{i=1}^m \lambda_i}{\sum_{n=1}^N \|x_n\|^2}$$

Η σχέση αυτή προκύπτει επειδή οι ιδιοτιμές λ_i του $\hat{\Sigma}$ αντιπροσωπεύουν τη διασπορά κατά μήκος των αντίστοιχων ιδιοδιανυσμάτων, η συνολική διασπορά των δεδομένων είναι το άθροισμα όλων των ιδιοτιμών $\lambda_1, \dots, \lambda_I$, υφιστάμενο με το πλήθος των δεδομένων N , και επομένως το ποσοστό ρ της διασποράς που ερμηνεύεται από τις πρώτες m κύριες συνιστώσες είναι το πηλίκο της διασποράς που ερμηνεύεται από αυτές προς τη συνολική διασπορά.

Άσκηση 2.5 (Markov Decision Process - Reinforcement Learning)

Έχουμε πλέγμα 4×4 , όπου ο στόχος είναι το $(3,3)$ και το $(2,2)$ είναι παγίδα. Έχουμε κινήσεις πάνω, κάτω, δεξιά, αριστερά. Οι ανταμοιβές είναι $+10$ αν φτάσει στο στόχο, -1 για κάθε κίνηση και -10 αν καταλήξει στην παγίδα. Οι κινήσεις είναι ντετερμινιστικές.

	0	1	2	3
0	S			
1				
2			T	
3				G

α) Τα στοιχεία μιας MDP για το πρόβλημα αυτό είναι η πλειάδα (S, A, T, R, γ) , όπου

• $S = \{ (0,0), (0,1), (0,2), (0,3), (1,0), (1,1), (1,2), (1,3), (2,0), (2,1), (2,2), (2,3), (3,0), (3,1), (3,2), (3,3) \}$

ο χώρος καταστάσεων

• $A: S \rightarrow S = \{ (x,y) \rightarrow (x,y+1), (x,y) \rightarrow (x,y-1), (x,y) \rightarrow (x+1,y), (x,y) \rightarrow (x-1,y) \}$, $x,y=0,\dots,3$

ο χώρος δράσεων

• $T: S \times A \times S \rightarrow [0,1] = \{ P(S'|S,a) = 1 \text{ αν η δράση } a \text{ οδηγεί σε έμφανη κίνηση, } P(S'|S,a) = 1 \text{ αν η δράση } a \text{ οδηγεί εκτός πλέγματος} \}$

η συνάρτηση μεταβάσεως

• $R: S \times A \times S \rightarrow R = \{10, x=y=3, -10, x=y=2, -1, x,y=0, \dots, 3\}$
 ~~$(x,y) \neq (2,2) \neq (3,3)$~~

η συνάρτηση ανταμοιβής

• $\gamma = 0,9$ ο συντελεστής ελάττωσης ανταμοιβής

3) Η εξίσωση Bellman για την αξία V_s^π μιας κατάστασης S υπό μια πολιτική π είναι η ακόλουθη:

$$V_s^\pi = E_s [r + \gamma V_{s'}^\pi] = \sum_{a \in A} P_\pi(a|s) \sum_{s' \in S} P(s'|s,a) [R(s,a,s') + \gamma V_{s'}^\pi]$$

πότε αμ. κινείται

όπου $P_\pi(a|s)$ η πιθανότητα να επιλέξουμε τη δράση a στην κατάσταση s , σύμφωνα με την πολιτική π .

γ) Υποθέτοντας $s_0 = (0,0)$ και $\gamma = 0,9$ έχουμε:

$$V_{s_0}^\pi = r_0 + \gamma \max_{s_0} r_1 + \gamma^2 \max_{s_1} r_2 + \dots = \sum_{a \in A} P_\pi(a|s_0) [R(s_0,a,s') + \gamma V_{s'}^\pi]$$

Χρησιμοποιώντας την πολιτική που οδηγεί το ρομπότ πάντα προς το στόχο, το ρομπότ θα χρειαστεί 6 κινήσεις για να φτάσει στο στόχο (3 προς τα κάτω και 3 προς τα δεξιά), εκ των οποίων οι 5 πρώτες έχουν ανταμοιβή -1 , καθώς είναι αυτές κινήσεις ~~που οδηγούν στο στόχο~~ και η τελευταία έχει ανταμοιβή 10 , καθώς το ρομπότ φτάνει στο στόχο. Επομένως, έχουμε:

$$\begin{aligned} V_{s_0}^\pi &= -1 - \gamma - \gamma^2 - \gamma^3 - \gamma^4 - \gamma^5 + 10\gamma^6 = - \sum_{i=0}^5 \gamma^i + \gamma^6 \cdot 10 = \\ &= \frac{1-\gamma^6}{1-\gamma} + 10\gamma^6 = \frac{1-0,9^6}{0,1} + 10 \cdot 0,9^6 = -4,69 + 10 \cdot 0,53 = \\ &= \boxed{0,63} \end{aligned}$$

δ) Η ύπαρξη της παγίδας $(2,2)$ εμποδίζει την τιμή V_5^{π} των καταστάσεων γύρω της, δηλαδή των καταστάσεων $(1,2), (2,1), (3,2), (2,3)$ ως εξής:

Από την εξίσωση Bellman, παρατηρούμε ότι η τιμή μιας
 εκ των δυνατών μεταστάσεων s της παρτίδας $(2,2)$,
 υπερπεριλαμβάνει τον ~~αριθμό~~ $R(s,a,s') = -10$, ο οποίος
 μειώνει σημαντικά την τιμή. ~~Αυτό~~ $\therefore$ συνεπώς, οι
 δυνατές αυτές μεταστάσεις, λόγω του αυξημένου κόστους,
 θα έχουν ως αποτέλεσμα την προσπάθεια του
 ρομπότ να αποφεύγει την παρτίδα, το οποίο αντιστοιχεί
 στην προσπάθεια προσέγγισης του στόχου, ιδιαίτερα
 λαμβάνοντας υπόψη το ότι για να φτάσει το ρομπότ
 στο στόχο πρέπει να περάσει είτε από την κατάσταση
 $(2,3)$ είτε από την $(3,2)$, οι οποίες είναι και
 οι δύο δυνατές της παρτίδας $(2,2)$ με μικρότερη
 τιμή $V(s)$. Έτσι, το ρομπότ θα τείνει να ακολουθεί
 διαδρομές που αποφεύγουν την περιοχή γύρω από την
 παρτίδα, ακόμη και αν αυτές οι διαδρομές μπορεί να
 απαιτούν περισσότερες κινήσεις και συνεπώς μεγαλύτερο
 κόστος.

Άσκηση 2.2:

β) Ο κώδικας που υλοποιεί το ζητούμενο του ερωτήματος είναι ο ακόλουθος:

```
import numpy as np
import pandas as pd
from sklearn.metrics import confusion_matrix, accuracy_score
from sklearn.preprocessing import LabelEncoder
from scipy.optimize import linear_sum_assignment

data_path = r"C:\\Users\\dthan\\Downloads\\Iris.csv"
data = pd.read_csv(data_path)

X = data.iloc[:, :-1].values
y_true = data.iloc[:, -1].values
label_encoder = LabelEncoder()
y_true_encoded = label_encoder.fit_transform(y_true)

def kmeans(X, k, epsilon=1e-5, max_iterations=300):
    n_samples, n_features = X.shape
    centers = X[np.random.choice(n_samples, k, replace=False)]
    prev_centers = np.zeros_like(centers)
    labels = np.zeros(n_samples)

    for iteration in range(max_iterations):
        distances = np.linalg.norm(X[:, np.newaxis] - centers, axis=2)
        labels = np.argmin(distances, axis=1)

        prev_centers = centers.copy()
        for i in range(k):
            points = X[labels == i]
            if len(points) > 0:
                centers[i] = np.mean(points, axis=0)

        if np.linalg.norm(centers - prev_centers) < epsilon:
            break

    return labels, centers

k = 3
predicted_labels, final_centers = kmeans(X, k)

conf_matrix = confusion_matrix(y_true_encoded, predicted_labels)
row_ind, col_ind = linear_sum_assignment(-conf_matrix)
optimal_labels = np.zeros_like(predicted_labels)
for true_label, pred_label in zip(row_ind, col_ind):
    optimal_labels[predicted_labels == pred_label] = true_label

success_rate = accuracy_score(y_true_encoded, optimal_labels)

print("Confusion Matrix:")
print(conf_matrix)
print(f"Success Rate: {success_rate:.4f}")
```

Το confusion matrix και το success rate του αλγορίθμου φαίνονται παρακάτω:

```
Confusion Matrix:  
[[ 0  0 50]  
 [ 0 49  1]  
 [49  1  0]]  
Success Rate: 0.9867
```

γ) Ο κώδικας που υλοποιεί το ζητούμενο του ερωτήματος είναι ο ακόλουθος:

```

import pandas as pd
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.metrics import confusion_matrix, accuracy_score

file_path = r"C:\\Users\\dthan\\Downloads\\Iris.csv"
data = pd.read_csv(file_path)

X = data[["PetalLengthCm", "PetalWidthCm"]]

kmeans = KMeans(n_clusters=3, random_state=42)
data['Cluster'] = kmeans.fit_predict(X)

species_to_numeric = {"Iris-setosa": 0, "Iris-versicolor": 1, "Iris-virginica": 2}
data['Species_numeric'] = data['Species'].map(species_to_numeric)

cm = confusion_matrix(data['Species_numeric'], data['Cluster'])

cluster_to_species = {i: cm[:, i].argmax() for i in range(3)}

data['Mapped_Cluster'] = data['Cluster'].map(cluster_to_species)

if data['Mapped_Cluster'].isna().any():
    print("Warning: Unmapped cluster values found!")

success_rate = accuracy_score(data['Species_numeric'], data['Mapped_Cluster'])

print("Confusion Matrix:")
print(cm)
print(f"Success Rate: {success_rate:.4f}")

plt.figure(figsize=(8, 6))
for cluster, species_num in cluster_to_species.items():
    cluster_points = X[data['Cluster'] == cluster]
    species_name = list(species_to_numeric.keys())[list(species_to_numeric.values().index(species_num))]
    plt.scatter(cluster_points["PetalLengthCm"], cluster_points["PetalWidthCm"], label=f'{species_name}')

centroids = kmeans.cluster_centers_
plt.scatter(centroids[:, 0], centroids[:, 1], s=200, c='red', marker='X', label='Centroids')

plt.title("k-means Clustering (Petal Features)")
plt.xlabel("Petal Length (cm)")
plt.ylabel("Petal Width (cm)")
plt.legend()
plt.show()

```


Το confusion matrix και το success rate του αλγορίθμου φαίνονται παρακάτω:

```

Confusion Matrix:
[[ 0 50  0]
 [48  0  2]
 [ 4  0 46]]
Success Rate: 0.9600

```

Η γραφική απεικόνιση της ομαδοποίησης στην οποία καταλήγει ο k-means με βάση τα δύο παραπάνω χαρακτηριστικά και των κέντρων των κλάσεων που εκτιμά ο αλγόριθμος είναι η ακόλουθη:



δ) Κοιτώντας τα αποτελέσματα των δύο ερωτημάτων παρατηρούμε πως η χρήση και των 4 χαρακτηριστικών αποδίδει καλύτερα. Αυτό οφείλεται στο γεγονός ότι όταν χρησιμοποιούμε 2 χαρακτηριστικά αντί για 4, παρουσιάζεται απώλεια πληροφορίας. Επιπλέον, παρατηρώντας το γράφημα της ομαδοποίησης, τα χαρακτηριστικά μήκος πετάλων και πλάτος πετάλων παρουσιάζουν επικάλυψη αναφορικά με τις κατηγορίες iris versicolor και iris virginica, κάτι που δυσκολεύει τον k-means που είναι αλγόριθμος αυστηρής ομαδοποίησης. Παρόλα αυτά, η απόδοση παρουσιάζει πολύ μικρή διαφορά, γεγονός που μας κάνει να συμπεράνουμε πως τα χαρακτηριστικά των πετάλων περιέχουν τη μεγαλύτερη ποσότητα πληροφορίας.